Predicción del éxito académico en educación superior

Ignacio Mascarell Agúndez
Proyecto Final — Aprendizaje Automático 2025/2026

1. Introducción

Este proyecto trabaja con un dataset de estudiantes de educación superior. El objetivo es estudiar qué factores influyen en el abandono, la permanencia y la graduación. Se llevan a cabo tres tareas: clasificación multiclase (predecir la situación final del estudiante), regresión (predecir la nota media del segundo semestre) y aprendizaje no supervisado (identificar perfiles de estudiantes). El propósito no consiste únicamente en obtener buenas métricas: también se busca entender qué variables tienen mayor peso y qué conclusiones podrían resultar útiles para una institución educativa.

El trabajo se organiza en módulos en `src/` (carga de datos, preprocesado, pipelines de clasificación y regresión, utilidades para el no supervisado) y cuatro notebooks que utilizan estos módulos para el EDA y las tres tareas. La ficha de variables generada en el EDA documenta el uso permitido de cada columna y se mantiene alineada con el subconjunto que emplea la tarea no supervisada.

2. Exploración inicial y análisis descriptivo

El dataset contiene 4424 observaciones y 37 variables, organizadas en bloques: demográficas, acceso y contexto previo, socioeconómicas/administrativas, macroeconómicas, rendimiento del primer semestre y rendimiento del segundo semestre. No hay valores nulos ni filas duplicadas, por lo que no es necesario imputar ni limpiar filas antes de modelar.

Se construyó una ficha de variables que indica el tipo, el bloque y el uso permitido de cada columna. De las 37 variables, 19 son numéricas y 18 son categóricas. La columna `usar_no_supervisado` de la ficha se calcula importando el subconjunto real desde `src/unsupervised.py`, de modo que EDA, ficha y tarea 3 quedan alineados.

Nota: en el fichero proporcionado, la variable objetivo de regresión aparece como `nota_media_2sem`. Corresponde a `unidades_curriculares_2do_semestre_calificacion` del enunciado.

La variable de clasificación presenta desbalanceo: graduado (49.9 %), abandono (32.1 %), matriculado (17.9 %). La variable de regresión va de 0 a 20, y se acumulan numerosos valores cercanos a 0 (probables abandonos). La mediana (12.2) describe mejor el rendimiento típico que la media (10.2) debido al peso de esa acumulación en 0.

La correlación entre `nota_media_1sem` y `nota_media_2sem` es de 0.837, lo que indica que el primer semestre será un buen predictor en regresión. También se observan correlaciones altas entre las variables del segundo semestre (asignaturas aprobadas, evaluadas, matriculadas) y el target de regresión. Esto es lógico, ya que pertenecen al mismo periodo, y por ese motivo se descartan como predictores en la tarea de regresión, para evitar leakage. La exploración tiene un objetivo descriptivo y de comprensión del problema; la elección de variables para cada tarea se basa en criterios metodológicos, no en haber observado el comportamiento del target en test. Los boxplots por clase muestran que las tres categorías se diferencian claramente en rendimiento: los que abandonan presentan notas y asignaturas aprobadas mucho más bajas, mientras que los graduados se concentran en la zona alta.

38th Conference on Neural Information Processing Systems (NeurIPS 2024).

3. Preprocesado y decisiones metodológicas

Todo el preprocesado se realiza dentro de pipelines de scikit-learn para evitar fugas entre train y test. El preprocesado (codificación de variables categóricas y escalado de variables numéricas) se integra dentro del pipeline, de modo que en cada ajuste se aprende únicamente sobre el train correspondiente y no se mezcla información entre train, validación y test. Se aplica un split 80/20 con semilla fija (`random_state=42`). En clasificación, el split es estratificado para mantener la proporción de las tres clases en ambos conjuntos.

Las variables numéricas se estandarizan con `StandardScaler`. Es necesario para los modelos sensibles a la escala, como la regresión logística o Ridge, y no afecta a los modelos de árboles. Las categóricas se codifican con `OneHotEncoder` con `handle_unknown='ignore'`, de modo que si en test aparece alguna categoría poco frecuente que no estaba en train, el pipeline no falle.

El test se utiliza una única vez, al final de cada tarea, exclusivamente para estimar la capacidad de generalización. El flujo en las tareas supervisadas es: (1) split train/test, (2) selección del modelo con validación cruzada únicamente sobre train, (3) fijación del mejor modelo, (4) una sola evaluación en test, y (5) cierre de la parte predictiva. Tras esa evaluación no se vuelve a tocar el modelo ni se toman decisiones que dependan del resultado de test. Las comparaciones entre modelos se realizan con validación cruzada sobre train (5 folds, estratificada en clasificación y `KFold` estándar en regresión). De este modo se evita que el modelo se elija con información del test y el número final proviene de una única evaluación.

En todas las tareas se fija `random_state=42` en particiones, PCA y modelos con aleatoriedad. El análisis de estabilidad del no supervisado es el único apartado donde se utilizan varias semillas distintas a propósito, con el fin de comprobar la robustez de los resultados.

4. Clasificación

Se predice la situación final del estudiante entre tres clases: Abandono, Matriculado y Graduado. Se utiliza macro F1 como métrica principal, ya que trata las tres clases por igual. Con desbalanceo, la accuracy por sí sola es engañosa: un modelo que siempre predice 'graduado' obtiene 49.9 % de accuracy pero un macro F1 de 0.222. Se reporta también balanced accuracy como comprobación.

Se compararon tres modelos con validación cruzada estratificada (5 folds): regresión logística, Random Forest y Gradient Boosting. Se probaron dos versiones: base (sin primer semestre) y extendida (con primer semestre). La versión base responde a la pregunta de cuánto se puede anticipar con la información disponible al matricularse; la extendida, a cuánto se gana al incorporar el rendimiento temprano.

Modelo	Versión	Macro F1 (CV)
Logística	Base	0.536
Random Forest	Base	0.495
Logística	Extendida	0.673
Random Forest	Extendida	0.632
Gradient Boosting	Extendida	0.673

Table 1: Macro F1 en validación cruzada 5-fold. La versión extendida añade las seis variables del rendimiento del primer semestre.

Los mejores resultados en validación cruzada son muy similares entre regresión logística y Gradient Boosting. Siguiendo el criterio automático de selección por macro F1 medio en CV implementado en el notebook, el modelo seleccionado fue Gradient Boosting. La elección es razonable: permite capturar relaciones no lineales e interacciones sin perder macro F1 frente al modelo lineal, y al haber bloques categóricos grandes (cursos, ocupaciones) la flexibilidad adicional puede ser útil.

El modelo final obtiene en test: accuracy 0.745, macro F1 0.657, balanced accuracy 0.650. La clase peor predicha es 'matriculado' (F1=0.37), la más ambigua de las tres, ya que un estudiante matriculado puede acabar tanto graduándose como abandonando. La Figura 1 muestra la matriz de

confusión: el modelo distingue bien abandono y graduado entre sí, y la mayor parte de los errores caen en la clase intermedia.

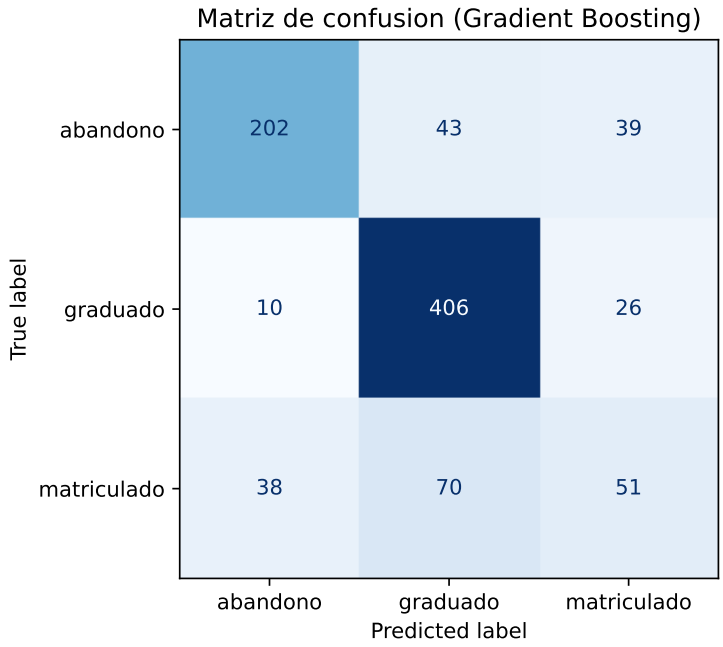


Figure 1: Matriz de confusión del modelo final (Gradient Boosting) en test. Los errores se reparten sobre todo entre 'matriculado' y las otras dos clases.

Incorporar el primer semestre eleva el macro F1 de $\sim$0.5 a $\sim$0.67. La importancia interna del modelo (impureza en árboles, valor absoluto del coeficiente en lineales) confirma lo que ya se intuía en el EDA: `asignaturas_1sem_aprobadas`, `nota_media_1sem` y `matricula_al_dia` son los predictores con mayor peso, en línea con lo que aparece en los modelos de árboles del proyecto.

5. Regresión

Se predice `nota_media_2sem`. Esta tarea requiere especial cuidado por el leakage: cualquier variable del segundo semestre contiene información del mismo periodo o prácticamente equivalente al target, y utilizarla como predictor elevaría las métricas de forma artificial y haría que el experimento perdiera sentido (la idea es anticipar el rendimiento, no explicarlo con sí mismo). Por este motivo, en regresión se excluyen todas las variables agregadas del segundo semestre, dado que coinciden en el tiempo con `nota_media_2sem` o son prácticamente equivalentes a la variable objetivo. De incluirlas, se introduciría fuga de información y la evaluación quedaría artificialmente alta. Los predictores que sí se utilizan se agrupan en tres bloques: variables de entrada y contexto (las disponibles al matricularse), variables del primer semestre (las disponibles al cierre del primer periodo) y variables macroeconómicas.

5.1. Variables excluidas por leakage

También se excluye `objetivo` (target de clasificación), ya que es un resultado final, no un predictor. El conjunto de predictores que sí se utiliza combina perfil del estudiante, acceso y contexto previo, situación socio-administrativa, macroeconómicas y rendimiento del primer semestre.

Variable excluida	Motivo
`asignaturas_2sem_convalidadas`	Información contemporánea al target
`asignaturas_2sem_matriculadas`	Información contemporánea al target
`asignaturas_2sem_evaluadas`	Información contemporánea al target
`asignaturas_2sem_aprobadas`	Prácticamente equivalente al target
`asignaturas_2sem_sin_evaluacion`	Información contemporánea al target

Table 2: Variables del bloque de segundo semestre excluidas como predictores en regresión.

5.2. Resultados

Modelo	RMSE (CV)	R^2 (CV)
Ridge	2.649	0.739
Elastic Net	2.659	0.737
Random Forest	2.471	0.772
Gradient Boosting	2.514	0.765

Table 3: Comparación de modelos de regresión en validación cruzada 5-fold.

El mejor modelo (Random Forest) obtiene en test: RMSE 2.728, MAE 1.404, R^2 0.725. El baseline (predecir la media) da un RMSE de 5.203 y un R^2 prácticamente 0. La mejora frente al baseline es notable, por lo que el resultado no proviene únicamente de aprovechar la variabilidad marginal del target.

Sin el primer semestre, el R^2 baja a 0.29–0.32. Con él, sube a 0.74–0.77. La diferencia es considerable y confirma que el rendimiento temprano es el bloque más informativo. La variable más influyente es `asignaturas_1sem_aprobadas` (70 % de la importancia), seguida de `nota_media_1sem` (7.5 %). El resto aporta relativamente poco.

El análisis de residuos muestra que el error se acumula en la zona de notas reales cercanas a 0, que corresponde a estudiantes que abandonaron sin evaluarse: el modelo tiende a predecir una nota más alta que la real, lo cual tiene sentido, ya que ese 0 no refleja un nivel académico bajo, sino la ausencia de evaluación. Este patrón es interesante para una institución: el modelo sirve para estimar el rendimiento esperado, pero no para detectar abandono directamente (esa función la cumple mejor la tarea de clasificación).

6. Aprendizaje no supervisado

Se trabajó con un subconjunto de 19 variables que combina perfil del estudiante (edad, género, desplazado, internacional), acceso y contexto (nota de admisión, nota de cualificación previa, orden de solicitud), situación administrativa (deudor, matrícula al día, becado), rendimiento del primer semestre (seis variables) y contexto macroeconómico (tasa de desempleo, inflación, PIB). Se dejaron fuera las variables objetivo, las del segundo semestre y varias categóricas de alta cardinalidad (ocupación y cualificación de los padres, nacionalidad, curso, modo de solicitud, cualificación previa), dado que al codificarlas con one-hot generarían numerosas columnas binarias que dominarían el PCA y el clustering de forma artificial. La idea es mantener una segmentación interpretable, centrada en atributos del estudiante y su rendimiento temprano.

La primera componente principal (23.8 % de varianza) está dominada por las variables de rendimiento del primer semestre. Puede interpretarse como un eje de rendimiento académico temprano. La segunda componente recoge el resto del perfil socio-administrativo y del contexto.

K-Means con k=3 identifica tres perfiles (Tabla 4). Los criterios internos del clustering apuntan a que la estructura más compacta aparece en k=2, con la silueta más alta. No obstante, también se analiza la solución k=3, ya que aporta una segmentación más fina y más útil para interpretar: permite separar perfiles que k=2 agrupa en un solo bloque. La coincidencia con las tres clases del target no se utiliza como criterio principal de selección, sino únicamente como referencia para comparar posteriormente si los grupos encontrados presentan diferencias académicas relevantes.

Cluster	N	Asig. apr. 1sem	Nota 1sem	% Abandono	% Graduado
0 (mayoría)	3416	5.12	12.71	22.8 %	57.1 %
1 (convalid.)	288	11.51	12.63	24.3 %	62.5 %
2 (riesgo)	720	0.00	0.03	79.4 %	10.7 %

Table 4: Perfil medio y distribución del target por cluster. La variable objetivo no se utilizó para construir los clusters.

La Figura 2 muestra la proyección 2D con los clusters superpuestos. El cluster 2 (riesgo) queda separado del resto en la dirección del PC1, que es el eje de rendimiento temprano, lo que confirma que ese perfil se identifica principalmente por rendimiento nulo en el primer semestre.

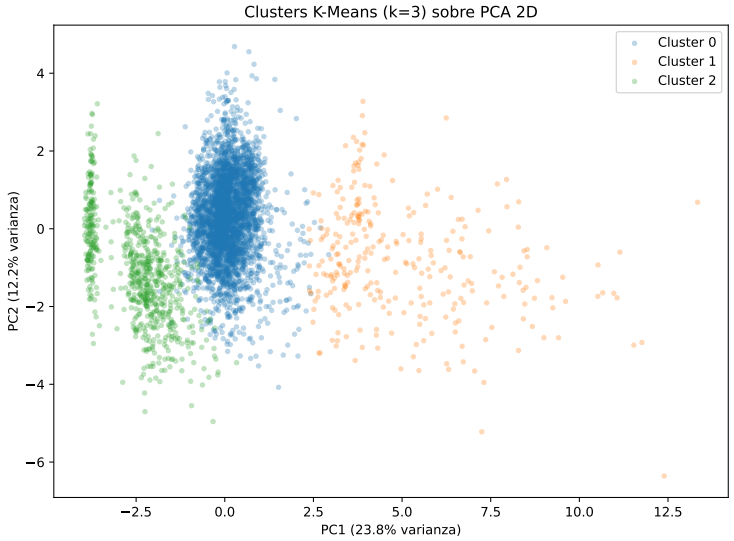


Figure 2: Clusters de K-Means (k=3) sobre la proyección PCA 2D del subconjunto razonado. El cluster de riesgo aparece claramente separado en la zona inferior del PC1.

Las variables `objetivo` y `nota_media_2sem` no se utilizaron para construir el clustering ni para escoger el número de grupos. La k se elige con criterios internos del clustering (inercia, silueta y estabilidad), no con el target. Estas variables se emplean únicamente a posteriori para interpretar los grupos y valorar si presentan diferencias académicas relevantes.

El cluster 2 concentra el 79.4 % de los abandonos. Como la variable objetivo no participó en la construcción de los clusters, esa relación procede directamente de los datos. La comparación con clustering jerárquico muestra un solapamiento elevado, y la silueta se mantiene estable en 10 submuestras del 80 % (media 0.261, desviación 0.001). El valor absoluto de la silueta es moderado: los clusters son estables, pero la separación entre grupos no es nítida, algo esperable en un problema con mezcla de variables numéricas y categóricas.

7. Interpretación crítica

Las asignaturas aprobadas y la nota media del primer semestre son los predictores con mayor peso en las tres tareas. El estado de matrícula al día también aparece de forma recurrente. El cluster de riesgo (rendimiento nulo en el primer semestre) confirma que el abandono se puede detectar de forma temprana, y además emerge de un análisis que no ha utilizado la variable objetivo.

Sin el primer semestre, la capacidad predictiva disminuye notablemente (R^2 de 0.77 a 0.32 en regresión, macro F1 de 0.67 a 0.5 en clasificación). Las variables de entrada y contexto, por sí solas, no bastan para anticipar la trayectoria del estudiante. Esto tiene una lectura práctica: el perfil previo

(demografía, contexto familiar, notas de acceso, macroeconomía) explica una parte del resultado, pero la señal fuerte aparece cuando se observa el comportamiento académico inicial.

El no supervisado identifica tres perfiles diferenciados: rendimiento medio-alto (mayoría), convalidaciones (grupo pequeño con muchas asignaturas convalidadas y buena trayectoria) y riesgo (rendimiento nulo, 79 % de abandono). Una institución podría utilizar el rendimiento del primer semestre como aviso temprano y vigilar el estado de matrícula y las becas como variables administrativas accionables, dado que son las que están al alcance de una política concreta.

La coincidencia entre las tres tareas refuerza la conclusión: la clasificación, la regresión y el clustering, cada uno por su lado, apuntan al mismo bloque de variables como el más informativo. Esto hace que la historia que cuenta el proyecto sea consistente entre las tres tareas.

8. Conclusiones y limitaciones

Es posible predecir la trayectoria del estudiante y su rendimiento futuro con precisión razonable utilizando información previa y del primer semestre. El primer semestre es el bloque más informativo en las tres tareas. Existen perfiles de estudiantes con trayectorias distintas que emergen del análisis no supervisado sin utilizar la variable objetivo. Un modelo lineal obtiene resultados similares a los ensembles, lo que indica que buena parte de la relación es aditiva; la ganancia del modelo no lineal es pequeña.

Limitaciones:

1) El dataset es observacional: correlación no implica causalidad. Que una variable sea predictiva no significa que modificarla cambie el resultado del estudiante. 2) Las variables de rendimiento son agregadas (conteos y medias), por lo que no se pueden analizar patrones a nivel de asignatura individual. 3) Si el primer semestre no está disponible, la capacidad predictiva se reduce notablemente. 4) La silueta moderada de los clusters indica que la separación entre grupos no es nítida; los resultados del clustering son un punto de partida para hipótesis, no una clasificación cerrada. 5) El modelo puede ser sensible a la partición train/test concreta, aunque la validación cruzada y las semillas fijas reducen ese riesgo. 6) El desbalanceo entre clases en clasificación no se ha corregido (no se han utilizado pesos ni remuestreo). La clase ‘matriculado’, que es la menos frecuente y la más ambigua, sigue siendo la peor predicha.

9. Uso de la inteligencia artificial

El proyecto entregado es completamente trabajo personal. Sin embargo, la inteligencia artificial me ha servido como una herramienta de ayuda y guía durante el desarrollo del proyecto. A continuación, se explica en qué aspectos me he apoyado en la inteligencia artificial.

En primer lugar, la inteligencia artificial me ha servido para validar mis planteamientos y razonamientos en cuanto al desarrollo general del proyecto. Por ejemplo, en un principio, mi idea era únicamente estudiar el dataset tal y como hemos aprendido en clase. El tema 2.1 recoge que hay que estudiar los valores faltantes, outliers, analizar las variables continuas y otros detalles. En cambio, la inteligencia artificial, me propuso hacer un EDA, que realmente es una versión más completa de lo que pretendía hacer. Por otro lado, también me sugirió estructurar el proyecto en notebooks de jupyter para desarrollar las tareas y archivos Python para las funciones, tal y como se hace en las prácticas. De esta manera, mi proyecto queda más estructurado. En adición, en ciertos casos la inteligencia artificial me ha ayudado a validar mis estrategias. Por ejemplo, al estudiar el dataset y ver que estaba desbalanceado, creía que la mejor opcón sería hacer down-sampling. Sin embargo, la IA me propuso hacer estratificación en las tareas posteriores porque no tenía suficientes datos como para despreciarlos y perder tanto la información su propia información como la aportada por el desbalance entre clases.

En segundo lugar, la inteligencia artificial me ha ayudado enormemente en la elaboración de códigos en aspectos que no domino. Este es sin duda el aspecto en el que más me he apoyado en la IA. En primer lugar, la inteligencia artificial me ha servido de gran ayuda para las construcciones de gráficos, histogramas y otros. Esto se debe a que no domino los códigos de representación gráfica con `matplotlib`. Por otro lado, en ciertos conceptos que dominaba teóricamente pero me costaba ver la aplicación directa mediante Python, como el extraer la importancia de las variables, la inteligencia

artificial ha sido una herramienta de gran ayuda. Finalmente, la IA me ha servido para corregir ciertos errores de programación que iba teniendo. De esta manera, me ha quedado un código correcto.

En conclusión, la inteligencia artificial ha sido una herramienta de gran ayuda durante el proyecto. Me ha servido en aspectos relacionados con el desarrollo general del proyecto y con el código. En cuanto al desarrollo del proyecto me ha guiado y sugerido ideas. Por otro lado, en relación con el código me ha ayudado en campos que no domino, como la construcción de gráficos con `matplotlib` entre otros. Sin embargo, a pesar de su ayuda, el trabajo es completamente personal.